Workshop: Impacto Social y Responsabilidad en el Proyecto de IA

Sistema Inteligente de Priorización de Riesgo y Asignación de Visitas Domiciliarias de Salud

Romel Alberto Vera Macías

Jhon Henry Quimi Loza

Maestría en Inteligencia Artificial, Universidad Espíritu Santo (UEES)

Proyecto Integrador

Docente: Gladys María Villegas Rugel

Octubre de 2026

Parte 1. Contexto del proyecto

1.1 Descripción del sistema

Problema. En los programas de valoración de salud en el hogar (IHA/HRA) que administran aseguradoras de Estados Unidos para afiliados de Medicare, Medicaid y Marketplace, cerca del 23% de las citas termina en inasistencia (Dantas et al., 2018), y el personal clínico itinerante (Nurse Practitioners, NP) se asigna solo por cercanía, por lo que cada inasistencia es un viaje desperdiciado.

Funcionalidad. Un modelo de Gradient Boosting estima la probabilidad de inasistencia de cada visita (AUC de 0.741), la explica con SHAP y la combina con la distancia para ordenar qué visitas confirmar primero, con umbrales por grupo de edad y un canal para solicitar la revisión humana de cada predicción, en una interfaz web en Streamlit.

Usuarios y dominio. Lo usan los coordinadores de programación; benefician de forma indirecta a afiliados y NP. El dominio es la salud preventiva en el hogar, regulado y con población vulnerable.

1.2 Alcance de implementación

Se implementaría en el equipo de programación de un programa IHA/HRA como herramienta interna; hoy es un prototipo con datos públicos (Hoppen, 2016). Afectaría a todos los afiliados con visita agendada (miles por mes en programas multiestatales, muchos de ellos adultos mayores), a los coordinadores y a los NP.

Decisiones que informa. El sistema no toma decisiones: informa el orden de las llamadas de confirmación y sugiere qué fracción de visitas confirmar primero según la capacidad del equipo. No decide quién recibe una visita, no cancela ni reprograma citas y no cambia la

asignación geográfica de los NP; la decisión final siempre es del coordinador, que puede apartarse de la recomendación.

Parte 2. Análisis de stakeholders

Se identificaron cinco grupos de stakeholders (Tabla 1). La Tabla 2 responde, para cada uno, las tres preguntas de la guía.

Tabla 1

Stakeholders del sistema: beneficios, riesgos y poder

Stakeholder	Descripción	Beneficios	Riesgos	Poder/ Voz
Afiliados	Personas con una visita agendada	Visita confirmada a tiempo; menos reprogramaciones	Trato distinto por su riesgo; percepción de vigilancia; errores del modelo	Bajo
Adultos mayores y afiliados de bajos ingresos	Subgrupos vulnerables (65 años o más; Medicaid)	Con la mitigación, igual cobertura que el resto	Sin mitigación, solo 30.6% de sus inasistencias detectadas; el barrio actúa como indicador socioeconómico	Bajo
Coordinadores de programación	Usuarios directos	Lista priorizada y explicada	Sesgo de automatización; más llamadas (45.1% de citas señaladas)	Medio
Nurse Practitioners	Personal que viaja a los domicilios	12.6% menos millas desperdiciadas (simulación)	Cambios de ruta; uso de métricas para evaluarlos	Medio
Organización (aseguradora)	Responsable del programa y de los datos	Más visitas con la misma dotación	Riesgo legal y reputacional (discriminación, privacidad)	Alto

Tabla 2

Efecto en cada stakeholder, consideración en el diseño y protección de sus intereses

Stakeholder	¿Cómo lo afecta?	¿Considerado en el diseño?	¿Cómo se protegen sus intereses?
Afiliados	Cambia el orden de su llamada de confirmación, no su derecho a la visita	Sí: desempeño evaluado por subgrupos	Uso limitado a confirmar; la app no guarda datos
Adultos mayores y bajos ingresos	Sin corrección, recibirían menos confirmaciones	Sí: motivó una mitigación implementada	Umbrales por grupo de edad: recall de 70.3% a 74.0% en todos
Coordinadores	Confirman primero las visitas marcadas	Sí: interfaz para usuarios no técnicos	Deciden, ven la explicación SHAP y pueden pedir revisión
Nurse Practitioners	Menos visitas sin paciente	Parcialmente: no fueron consultados	Asignación por cercanía intacta; no se usa para evaluarlos

Stakeholder	¿Cómo lo afecta?	¿Considerado en el diseño?	¿Cómo se protegen sus intereses?
Organización	Más eficiencia, con responsabilidad legal	Sí: limitaciones y regulación documentadas	Documentación, versionado, pruebas y monitoreo

Parte 3. Evaluación de impacto social

3.1 Impactos positivos

1. Menos desplazamiento desperdiciado. Confirmar primero el 20% de visitas con mayor riesgo por distancia redujo el desplazamiento desperdiciado 12.6% (IC 95%: 9.5 a 15.7), frente a 8.9% con solo la distancia y 5.0% al azar. *Beneficiados:* NP y organización. *Evidencia:* simulación de Monte Carlo con 2,000 réplicas, suponiendo que la confirmación reduce las inasistencias en 25% (Robotham et al., 2016).

2. Más valoraciones preventivas efectivas. Cada inasistencia evitada o reprogramada a tiempo es una valoración que sí ocurre. *Beneficiados:* afiliados con condiciones crónicas. *Evidencia:* el modelo detecta el 71.0% de las inasistencias, frente al 1.7% con el umbral por defecto de 0.5.

3. Cobertura más equitativa entre grupos de edad. La mitigación hace que la probabilidad de recibir una confirmación no dependa de la edad. *Beneficiados:* adultos de 56 años o más. *Evidencia:* el recall de los pacientes de 65 años o más subió de 30.6% a 74.0%, y la diferencia de igualdad de oportunidades entre grupos bajó de 0.603 a 0.037 (Hardt et al., 2016).

3.2 Impactos negativos y riesgos

Tabla 3

Impactos negativos y riesgos sociales

Riesgo	Descripción	Grupos vulnerables	Severidad	Probabilidad
1. Uso del riesgo para restringir atención	Emplear la probabilidad para no visitar, retrasar o sobreagendar a quienes más faltan, en lugar de ayudarlos	Afiliados con más barreras de acceso (transporte, movilidad, bajos ingresos)	Alta	Media
2. Errores del modelo	Con un AUC de 0.741, el 29% de las inasistencias no se detecta y dos	Todos; los falsos negativos pesan más en	Media	Alta

Riesgo	Descripción	Grupos vulnerables	Severidad	Probabilidad
	de cada tres citas señaladas son falsas alarmas	los adultos mayores		
3. Indicadores socioeconómicos	El barrio y el programa social aumentan el riesgo estimado, lo que concentra más llamadas en comunidades pobres	Afiliados de bajos ingresos y de barrios con alta inasistencia	Media	Media
4. Transferencia de dominio	El modelo se entrenó con citas ambulatorias de Brasil (2016), no con visitas domiciliarias de EE. UU.	Todos los afiliados, si se usa sin reentrenar	Alta	Alta (sin reentrenar)

3.3 Análisis de equidad

¿Reduce o aumenta desigualdades? Sin mitigación ni supervisión las **aumentaría**: con un umbral único, los adultos mayores recibían muchas menos confirmaciones, y un mal uso del riesgo podría excluir a quienes ya enfrentan más barreras. Con umbrales por grupo de edad y uso limitado a confirmar, las **reduce**, porque dirige más apoyo a quien tiene más probabilidad de perder su visita.

Beneficios y riesgos. Los beneficios operativos se concentran en la organización y los NP; los riesgos recaen en los afiliados con alto riesgo estimado (más contactos) y en los adultos mayores (AUC de 0.707). **Acceso y barreras:** el sistema lo usa el personal, pero la confirmación es telefónica: quienes no tienen teléfono, tienen discapacidad auditiva o no hablan el idioma del equipo podrían quedar excluidos, igual que los pacientes sin historial, para quienes el modelo es menos preciso.

Parte 4. Riesgos éticos específicos

La Tabla 4 resume el checklist de la guía aplicado al proyecto; la Tabla 5 desarrolla los cinco riesgos éticos prioritarios.

Tabla 4

Checklist de riesgos éticos aplicado al proyecto

Dimensión	Estado en el proyecto
Fairness y sesgo	Usa edad y sexo; 65% de mujeres y 13% de mayores de 65 en prueba; equidad evaluada

Dimensión	Estado en el proyecto
	por grupo
Privacidad	Datos públicos y anónimos; en uso real, datos de salud con riesgo de reidentificación
Transparencia	SHAP por predicción y limitaciones en la app; riesgo de leer las explicaciones como causas
Autonomía	Decide el coordinador; no coacciona al afiliado; riesgo de sesgo de automatización
Seguridad	Los errores causan viajes perdidos o llamadas innecesarias, sin daño clínico directo
Accountability	Versionado, pruebas, registro de eventos y canal de revisión; falta la auditoría periódica

Tabla 5

Riesgos éticos prioritarios

Riesgo	Descripción en el proyecto	Evidencia	Severidad	Grupo afectado
R1. Discriminación por edad	La cobertura de las inasistencias cae con la edad cuando se usa un umbral único	Recall de 30.6% (65 o más) frente a 90.9% (19 a 35); AUC de 0.707 frente a 0.741 global	Alta	Adultos de 56 años o más
R2. Privacidad y reidentificación	En un despliegue real, el historial de citas, la edad y el barrio son datos de salud identificables	La combinación de pocas variables cuasiidentificadoras puede reidentificar a una persona	Alta	Todos los afiliados
R3. Explicaciones mal interpretadas	SHAP explica al modelo, no causas, y puede inducir decisiones erróneas	El SMS aparece asociado a más inasistencias (27.6% frente a 16.7%), pero ajustado por antelación la razón de momios es 0.77	Media	Coordinadores y afiliados
R4. Sesgo de automatización	Los coordinadores podrían seguir la lista sin criterio propio y dejar de confirmar visitas no marcadas	Fenómeno documentado en usuarios de sistemas automatizados (Parasuraman y Manzey, 2010); el 29% de las inasistencias no se marca	Media	Afiliados no marcados
R5. Apelación y auditoría insuficientes	El afiliado no puede cuestionar directamente una predicción y no hay una auditoría periódica definida	La Sección 1557 exige identificar y mitigar el riesgo de discriminación de las herramientas de apoyo (HHS, 2024)	Media	Afiliados y organización

Priorización. R1 y R2 se califican de severidad alta porque comprometen derechos (igualdad de trato por edad y privacidad de la información de salud) y porque su daño recae en grupos con poca voz. R3 a R5 son de severidad media: sus consecuencias dependen de cómo se use el sistema y pueden corregirse con diseño y políticas. Ningún riesgo se descartó por su baja probabilidad: en un despliegue real, la combinación de datos de salud, población vulnerable y decisiones repetidas miles de veces al mes hace que incluso los errores pequeños se acumulen.

Balance de los datos. La clase positiva representa el 20.2% de las citas; no se rebalanceó para no distorsionar las probabilidades que el sistema usa para priorizar. El desequilibrio relevante es demográfico: los pacientes de 65 años o más son solo el 13% del conjunto de prueba, lo que explica en parte la menor discriminación del modelo en ese grupo y refuerza la necesidad de monitorearlo por separado.

Parte 5. Estrategias de mitigación

La Tabla 6 presenta una estrategia por riesgo, siguiendo la plantilla de la guía. Como pide la guía para el proyecto final, las estrategias de alta prioridad ya están implementadas, total o parcialmente, en el sistema.

Tabla 6

Estrategias de mitigación por riesgo

Riesgo	Estrategia propuesta	Tipo	Implementación (pasos)	Cuándo / Responsable	Efectividad / Estado
R1	Umbrales por grupo de edad con igual recall objetivo (igualdad de oportunidades)	Técnica y diseño	1) Calcular recall por grupo con IC bootstrap. 2) Elegir un umbral por grupo con predicciones fuera de muestra. 3) Activarlo por defecto en la app	Antes del despliegue y mensual / Data scientist	Alta / **Implementada**
R2	Minimización y protección de datos con controles HIPAA	Política y diseño	1) Usar solo las 13 variables del modelo, sin nombres. 2) No almacenar datos en la app. 3) Cifrado, control de acceso y acuerdo de asociado comercial en producción	Antes del despliegue / Organización (oficial de privacidad)	Alta / Parcial (1 y 2 implementados)
R3	Comunicar que SHAP no indica causas	Educación y diseño	1) Nota fija bajo cada explicación. 2) Ejemplo del SMS en la sección de limitaciones. 3) Capacitación breve a coordinadores	Antes del despliegue / Equipo de desarrollo	Media / Parcial (1 y 2 implementados)
R4	Supervisión humana obligatoria y revisión de casos no marcados	Política y diseño	1) La app solo ordena; no cancela ni reprograma. 2) Protocolo: confirmar también visitas no marcadas según la capacidad. 3) Revisar mensualmente las inasistencias no detectadas	Continuo / Líder de programación	Media / Parcial (1 implementado)
R5	Canal de apelación y	Política	1) Formulario para que un	Antes del	Alta / Parcial (1

Riesgo	Estrategia propuesta	Tipo	Implementación (pasos)	Cuándo / Responsable	Efectividad / Estado
	auditoría periódica		coordinador o afiliado pida revisar una decisión. 2) Auditoría trimestral de sesgo. 3) Auditoría externa anual	despliegue / Organización (comité de ética)	implementado en la app)

Para los riesgos 1 y 4 de la Tabla 3 se agregan dos políticas: prohibir por escrito el uso del riesgo para negar o retrasar visitas, y exigir reentrenar con datos del programa real antes de cualquier uso.

Parte 6. Framework de responsabilidad

6.1 Cadena de responsabilidad

Tabla 7

Cadena de responsabilidad

Rol	Responsabilidades	Rendición de cuentas
Desarrolladores (equipo del proyecto)	Implementación técnica correcta, pruebas y validación de entradas	16 pruebas unitarias, estilo verificado y control de versiones
Data scientists	Calidad de datos, ausencia de fuga de información y equidad	Auditoría de sesgo por grupo de edad y sexo; reporte de métricas en cada versión
Product owner (líder de programación)	Decisiones de diseño, umbral y capacidad de confirmación	Documentación de los trade-offs (por ejemplo, precisión de 0.334 a 0.320 por la mitigación)
Coordinadores (usuarios)	Decisión final sobre cada visita	Registro de las decisiones que se apartan de la recomendación
Organización	Gobernanza, recursos, privacidad y cumplimiento	Políticas de uso, comité de ética y supervisión del coordinador de la Sección 1557

6.2 Mecanismos de accountability

Tabla 8

Mecanismos de accountability

Mecanismo	Estado	Evidencia o frecuencia
Model card	Cumplido	models/README.md y docs/arquitectura.md (Mitchell et al., 2019)
Datasheet de los datos	Cumplido	data/README.md: origen, licencia y diccionario (Gebru et al., 2021)
Ethics statement	Cumplido	docs/consideraciones_eticas.md y este análisis
Revisión humana en decisiones críticas	Cumplido	El sistema solo ordena; el coordinador decide

Mecanismo	Estado	Evidencia o frecuencia
Proceso de apelación	Cumplido	Botón «Solicitar revisión» en cada predicción; solicitudes en CSV
Auditoría periódica	Propuesto	Trimestral de sesgo; externa anual
Métricas de fairness monitoreadas	Propuesto	Recall y AUC por grupo, mensualmente
Alertas por drift o anomalías	Propuesto	Alerta si el recall de un grupo baja de 60% o el Brier sube 10%
Reporte de incidentes	Parcial	Issues del repositorio; registro formal en producción
Información, limitaciones y explicaciones	Cumplido	Advertencia, «Acerca del modelo» y SHAP en la app

6.3 Plan de respuesta a incidentes

- **Detección:** alertas del monitoreo mensual y solicitudes de revisión de coordinadores o afiliados.
- **Respuesta inmediata:** volver a la versión validada anterior o confirmar por orden de agenda.
- **Investigación:** métricas por subgrupo, datos de entrada y SHAP de los casos afectados.
- **Corrección:** reprogramar con prioridad las visitas perjudicadas y reentrenar o recalibrar.
- **Prevención:** nueva prueba o alerta, y actualización de la documentación y la capacitación.

Parte 7. Consideraciones de compliance

Tabla 9

Regulaciones aplicables

Regulación	¿Qué requiere?	¿El proyecto cumple?	Cambios necesarios
HIPAA (EE. UU.)	Proteger la información de salud: mínimo necesario, seguridad y acuerdos con terceros	Sí en el prototipo (datos públicos, sin PHI)	Acuerdo de asociado comercial, cifrado, control de acceso y registro de auditoría
Sección 1557 de la ACA, 45 CFR § 92.210	Identificar y mitigar el riesgo de discriminación de herramientas de apoyo que usan edad o sexo	Parcialmente: equidad por edad evaluada y mitigada	Inventario formal de la herramienta y auditoría periódica (HHS, 2024)
Ley contra la Discriminación por Edad (1975)	Prohíbe discriminar por edad en programas con fondos federales	Sí, con los umbrales por grupo	Mantener el monitoreo por edad
CCPA/CPRA (California)	Derechos sobre datos personales; la PHI regulada por HIPAA está en gran parte exenta	No aplica al prototipo	Revisar datos no cubiertos por HIPAA
GDPR y AI Act de la UE	Base legal y protección de datos de salud; el AI Act clasifica como de alto riesgo los sistemas	No aplica (población de EE. UU.)	Si decidiera el acceso a visitas, sería de alto riesgo: el diseño solo informa el

Regulación	¿Qué requiere?	¿El proyecto cumple?	Cambios necesarios
	que evalúan el acceso a servicios de salud		orden
Leyes laborales	Uso justo de métricas de desempeño del personal	Sí: no evalúa a los NP	Prohibir su uso para evaluar a los NP

Un despliegue real requeriría asesoría legal, en particular para la Sección 1557, cuya aplicación ha sido objeto de litigios, y para el acuerdo de asociado comercial bajo HIPAA.

Parte 8. Reflexión y compromiso

8.1 Reflexión grupal

1. Dilema más difícil: eficiencia frente a equidad. Priorizar donde el modelo acierta más ahorra más millas, pero deja a los adultos mayores con menos confirmaciones; igualar su cobertura cuesta precisión (de 0.334 a 0.320). Chocan la beneficencia y la justicia (Beauchamp y Childress, 2019); lo resolvemos con una regla: el riesgo solo puede **agregar** apoyo, nunca quitarlo. **2. Lo que no habíamos considerado:** que una métrica global alta oculta brechas por subgrupo (Obermeyer et al., 2019), que una explicación correcta puede sugerir una causa falsa (el SMS) y que nunca consultamos a NP ni afiliados. **3. Cambios:** tras este análisis ya agregamos al sistema un canal de revisión de cada predicción; además, consultaríamos a NP y afiliados antes de un piloto y auditaríamos también por indicadores socioeconómicos.

8.2 Compromiso ético

Como creadores de este sistema de IA, nos comprometemos a:

- Evaluar mensualmente el recall y el AUC por grupo de edad y sexo.
- No permitir que el riesgo se use para negar, retrasar o sobreagendar visitas.
- Reentrenar y revalidar el modelo con datos autorizados antes de cualquier uso real.
- Actuar responsablemente si se identifican daños.
- Priorizar el bienestar de los usuarios y de los grupos vulnerables.
- Mantener la transparencia sobre las limitaciones del sistema.

Firma: Romel Alberto Vera Macías y Jhon Henry Quimi Loza. Fecha: octubre de 2026.

Referencias

Beauchamp, T. L., y Childress, J. F. (2019). *Principles of biomedical ethics* (8.ª ed.). Oxford University Press.

Dantas, L. F., Fleck, J. L., Cyrino Oliveira, F. L., y Hamacher, S. (2018). No-shows in appointment scheduling: A systematic literature review. *Health Policy, 122*(4), 412–421. https://doi.org/10.1016/j.healthpol.2018.02.002

Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., y Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM, 64*(12), 86–92. https://doi.org/10.1145/3458723

Hardt, M., Price, E., y Srebro, N. (2016). Equality of opportunity in supervised learning. En *Advances in Neural Information Processing Systems* (Vol. 29, pp. 3315–3323). Curran Associates.

Hoppen, J. (2016). *Medical appointment no shows* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/joniarroba/noshowappointments

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., y Gebru, T. (2019). Model cards for model reporting. En *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220–229). ACM. https://doi.org/10.1145/3287560.3287596

Obermeyer, Z., Powers, B., Vogeli, C., y Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. *Science, 366*(6464), 447–453. https://doi.org/10.1126/science.aax2342

Parasuraman, R., y Manzey, D. H. (2010). Complacency and bias in human use of automation: An attentional integration. *Human Factors, 52*(3), 381–410. https://doi.org/10.1177/0018720810376055

Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, por el que se establecen normas armonizadas en materia de inteligencia artificial. (2024). *Diario Oficial de la Unión Europea*, L 2024/1689. https://eur-lex.europa.eu/eli/reg/2024/1689/oj

Robotham, D., Satkunanathan, S., Reynolds, J., Stahl, D., y Wykes, T. (2016). Using digital notifications to improve attendance in clinic: Systematic review and meta-analysis. *BMJ Open, 6*(10), e012116. https://doi.org/10.1136/bmjopen-2016-012116

U.S. Department of Health and Human Services. (2024). Nondiscrimination in health programs and activities. *Federal Register, 89*(88), 37522–37703. https://www.federalregister.gov/d/2024-08711