Workshop: Impacto Social y Responsabilidad en el Proyecto de IA

Sistema Inteligente de Priorización de Riesgo y Asignación de Visitas Domiciliarias de Salud

Romel Alberto Vera Macías

Jhon Henry Quimi Loza

Maestría en Inteligencia Artificial, Universidad Espíritu Santo (UEES)

Proyecto Integrador

Docente: Gladys María Villegas Rugel

Octubre de 2026

Parte 1. Contexto del proyecto

1.1 Descripción del sistema

Problema. En los programas de valoración de salud en el hogar (IHA/HRA) que administran aseguradoras de Estados Unidos para afiliados de Medicare, Medicaid y Marketplace, parte de las visitas agendadas termina en inasistencia, y el personal clínico itinerante (Nurse Practitioners, NP) se asigna solo por cercanía, por lo que cada inasistencia es un viaje desperdiciado. La tasa promedio en consultas ambulatorias es de 23% (Dantas et al., 2018) y en nuestros datos, de 20.2%; no hallamos una cifra publicada propia de IHA/HRA, así que solo es un orden de magnitud y la tasa real debe medirse en el programa.

Funcionalidad. Un modelo de Gradient Boosting estima la probabilidad de inasistencia de cada visita (AUC de 0.741), la explica con SHAP y la combina con la distancia para ordenar qué visitas confirmar primero, con umbrales por grupo de edad y un canal para solicitar la revisión humana de cada predicción, en una interfaz web en Streamlit.

Usuarios y dominio. Lo usan los coordinadores de programación; benefician de forma indirecta a afiliados y NP. El dominio es la salud preventiva en el hogar, regulado y con población vulnerable.

1.2 Alcance de implementación

Se implementaría en el equipo de programación de un programa IHA/HRA como herramienta interna; hoy es un prototipo con datos públicos (Hoppen, 2016). Afectaría a los afiliados con visita agendada (miles por mes, muchos de ellos adultos mayores), a los coordinadores y a los NP.

Decisiones que informa. El sistema no toma decisiones: informa el orden de las llamadas de confirmación según la capacidad del equipo. No decide quién recibe una visita, no

cancela ni reprograma citas y no cambia la asignación de los NP; la decisión final es del coordinador.

Parte 2. Análisis de stakeholders

Se identificaron cinco grupos de stakeholders (Tabla 1). La Tabla 2 responde, para cada uno, las tres preguntas de la guía. En este documento, «adultos mayores» son los grupos de 56 a 64 y de 65 años o más.

Tabla 1

Stakeholders del sistema: beneficios, riesgos y poder

Stakeholder	Descripción	Beneficios	Riesgos	Poder/ Voz
Afiliados	Personas con una visita agendada	Visita confirmada a tiempo; menos reprogramaciones	Trato distinto por su riesgo; percepción de vigilancia; errores del modelo	Bajo
Adultos mayores y afiliados de bajos ingresos	Subgrupos vulnerables (56 a 64 y 65 años o más; Medicaid)	Con la mitigación, cobertura similar a la del resto	Sin mitigación, solo 31.7% (56 a 64) y 30.6% (65 o más) de sus inasistencias detectadas; el barrio y el programa social actúan como indicadores socioeconómicos	Bajo
Coordinadores de programación	Usuarios directos	Lista priorizada y explicada	Sesgo de automatización; más llamadas (45.1% de citas señaladas)	Medio
Nurse Practitioners	Personal que viaja a los domicilios	Simulado: 12.6% menos millas desperdiciadas (5.0% a 20.0% según el efecto supuesto)	Cambios de ruta; uso de métricas para evaluarlos	Medio
Organización (aseguradora)	Responsable del programa y de los datos	Más visitas con la misma dotación	Riesgo legal y reputacional (discriminación, privacidad)	Alto

Tabla 2

Efecto en cada stakeholder, consideración en el diseño y protección de sus intereses

Stakeholder	¿Cómo lo afecta?	¿Considerado en el diseño?	¿Cómo se protegen sus intereses?
Afiliados	Cambia el orden de su llamada de confirmación, no su derecho a la visita	Sí: desempeño evaluado por subgrupos	Uso limitado a confirmar; pueden objetar en la llamada y el coordinador pide revisión
Adultos mayores y bajos ingresos	Sin corrección, recibirían menos confirmaciones	Sí: motivó una mitigación implementada	Umbrales por grupo de edad: recall de 72.3% (56 a 64) y

Stakeholder	¿Cómo lo afecta?	¿Considerado en el diseño?	¿Cómo se protegen sus intereses?
			74.0% (65 o más); todos los grupos entre 70.3% y 74.0%
Coordinadores	Confirman primero las visitas marcadas	Sí: interfaz para usuarios no técnicos	Deciden, ven la explicación SHAP y pueden pedir revisión
Nurse Practitioners	Menos visitas sin paciente	Parcialmente: no fueron consultados	Asignación por cercanía intacta; no se usa para evaluarlos
Organización	Más eficiencia, con responsabilidad legal	Sí: limitaciones y regulación documentadas	Documentación, versionado, pruebas y monitoreo

Parte 3. Evaluación de impacto social

3.1 Impactos positivos

1. Menos desplazamiento desperdiciado del personal clínico (beneficio simulado).

Descripción: confirmar primero el 20% de visitas con mayor riesgo por distancia evita viajes a domicilios donde nadie atenderá. *Grupos beneficiados:* NP y organización. *Evidencia:* simulada, no medida. El conjunto de Brasil no trae distancias: se usaron 300 solicitudes en centroides reales de códigos postales de Ohio (U.S. Census Bureau, 2023) y 15 sedes de NP del NPI Registry (Centers for Medicare & Medicaid Services, s. f.), con la distancia a la sede más cercana, y en cada réplica se asignó a cada solicitud el riesgo y el desenlace de una cita real de prueba (asociación sintética). Con una reducción supuesta de 25% de las inasistencias por confirmación (Robotham et al., 2016), el desplazamiento desperdiciado bajó 12.6% (IC 95%: 9.5 a 15.7), frente a 8.9% con solo la distancia y 5.0% al azar (2,000 réplicas).

Sensibilidad del supuesto. Con 10% y 40% de reducción (Tabla 3), el beneficio de riesgo por distancia va de 5.0% a 20.0%, pero el orden de las políticas no cambia: siempre supera a usar solo la distancia (por 1.5, 3.7 y 5.8 puntos).

Tabla 3

Reducción simulada de las millas desperdiciadas según el efecto supuesto de la confirmación

Política de selección	10% de efecto	25% (base)	40% de efecto
Al azar	2.0 [1.0, 3.1]	5.0 [2.5, 7.7]	8.0 [4.1, 12.4]

Política de selección	10% de efecto	25% (base)	40% de efecto
Solo distancia (sin modelo)	3.6 [2.1, 4.9]	8.9 [5.3, 12.1]	14.2 [8.5, 19.4]
Por riesgo	3.8 [2.6, 5.2]	9.6 [6.6, 13.0]	15.3 [10.4, 20.6]
Riesgo × distancia	**5.0 [3.9, 6.2]**	**12.6 [9.5, 15.7]**	**20.0 [15.5, 24.8]**

Nota. Reducción media (%) con el 20% de 300 solicitudes confirmadas e IC 95% entre réplicas (1,000 réplicas con 10% y 40%). Resultados simulados.

2. Más valoraciones preventivas efectivas. *Descripción:* cada inasistencia evitada o reprogramada a tiempo es una valoración que sí ocurre. *Grupos beneficiados:* afiliados con condiciones crónicas. *Evidencia:* el modelo detecta el 71.0% de las inasistencias, frente al 1.7% con el umbral por defecto de 0.5.

3. Cobertura más equitativa entre grupos de edad. *Descripción:* la probabilidad de que una inasistencia real sea detectada y reciba confirmación pasa a ser similar entre grupos de edad, aunque no idéntica. *Grupos beneficiados:* adultos de 56 a 64 años y de 65 años o más. *Evidencia:* su recall subió de 31.7% a 72.3% y de 30.6% a 74.0%, la diferencia de igualdad de oportunidades bajó de 0.603 a 0.037 (Hardt et al., 2016) y todos los grupos quedaron entre 70.3% y 74.0%; el porcentaje de citas señaladas sigue variando por grupo (de 41.7% a 49.9%), porque sus tasas de inasistencia son distintas.

3.2 Impactos negativos y riesgos

La Tabla 4 presenta los cuatro impactos negativos o riesgos, con su severidad y su probabilidad.

Tabla 4

Impactos negativos y riesgos sociales

Riesgo o impacto negativo	Descripción del riesgo	Grupos vulnerables	Severidad	Probabilidad
1. Uso del riesgo para restringir atención	Emplear la probabilidad para no visitar, retrasar o sobreagendar a quienes más faltan	Afiliados con barreras de acceso (transporte, movilidad, bajos ingresos)	Alta	Media
2. Errores del modelo	Con un AUC de 0.741, el 29% de las inasistencias no se detecta y dos	Todos; los falsos negativos pesan más en	Media	Alta

Riesgo o impacto negativo	Descripción del riesgo	Grupos vulnerables	Severidad	Probabilidad
	de cada tres citas señaladas son falsas alarmas	los adultos mayores		
3. Indicadores socioeconómicos	El barrio y el programa social elevan el riesgo estimado y concentran más llamadas en beneficiarios y barrios vulnerables (Tabla 5)	Afiliados de bajos ingresos y de barrios con alta inasistencia	Media	Alta (medida)
4. Transferencia de dominio (R6)	Entrenado con citas ambulatorias de Brasil (2016), no con visitas domiciliarias de EE. UU.	Todos los afiliados, si se usa sin reentrenar	Alta	Alta

3.3 Análisis de equidad

¿Reduce o aumenta las desigualdades? Sin mitigación ni supervisión las **aumentaría**; con umbrales por grupo de edad y uso limitado a confirmar visitas, las **reduce**, porque dirige más apoyo a quien tiene más probabilidad de perder su visita.

Tabla 5

AUC y recall por edad, sexo y proxies socioeconómicos en el conjunto de prueba

Grupo	Citas	AUC [IC 95%]	Recall con umbral único [IC 95%]	Recall con umbrales por edad [IC 95%]
0 a 18	7,356	0.745 [0.732, 0.760]	82.3% [80.3, 84.4]	70.3% [68.1, 72.8]
19 a 35	6,029	0.736 [0.723, 0.751]	90.9% [89.4, 92.3]	72.9% [70.5, 75.5]
36 a 55	7,428	0.730 [0.710, 0.745]	68.5% [65.9, 71.3]	70.4% [67.9, 72.9]
56 a 64	3,224	0.714 [0.681, 0.743]	31.7% [27.3, 37.5]	72.3% [67.9, 76.5]
65 o más	3,594	0.707 [0.684, 0.729]	30.6% [25.9, 34.7]	74.0% [70.2, 77.8]
Mujeres	18,371	0.737 [0.728, 0.747]	70.9% [69.4, 72.5]	72.2% [70.8, 73.9]
Hombres	9,260	0.750 [0.737, 0.765]	71.1% [68.6, 73.4]	70.2% [67.8, 72.4]
Con Bolsa Família	2,763	0.757 [0.733, 0.781]	86.8% [84.0, 89.5]	83.2% [79.9, 86.2]
Sin Bolsa Família	24,868	0.738 [0.730, 0.747]	68.9% [67.3, 70.5]	70.0% [68.6, 71.5]
Barrios de vulnerabilidad alta	8,877	0.755 [0.743, 0.766]	75.2% [73.2, 77.0]	73.3% [71.1, 75.6]
Barrios de vulnerabilidad media	9,428	0.739 [0.727, 0.752]	73.0% [70.9, 75.3]	72.4% [69.9, 74.5]
Barrios de vulnerabilidad baja	9,326	0.725 [0.712, 0.740]	64.2% [61.7, 66.8]	68.8% [66.5, 71.3]

Nota. 27,631 citas de prueba. IC 95% por bootstrap por paciente (300 remuestreos). Los umbrales se fijan por edad; en las demás filas se muestra su efecto.

Lectura. La Tabla 5 suma al análisis por edad el sexo y dos proxies socioeconómicos: el programa social Bolsa Família y la vulnerabilidad del barrio (tercil de la proporción de beneficiarios en el barrio, calculada con el entrenamiento). La brecha principal es por edad

(recall de 31.7% y 30.6% en los dos grupos mayores con umbral único); por sexo no hay brecha relevante (70.9% y 71.1%); y en los proxies va en sentido contrario al temido: los beneficiarios y los barrios vulnerables reciben más cobertura porque faltan más, de modo que su riesgo es el uso indebido del puntaje (riesgo 1 de la Tabla 4).

- **Distribución de beneficios:** los beneficios operativos se concentran en la organización y los NP; los afiliados se benefician de forma indirecta, con más visitas que sí ocurren.
- **Distribución de riesgos:** los asumen los afiliados con alto riesgo estimado, entre ellos beneficiarios de programas sociales y residentes de barrios vulnerables (más contactos), y los adultos de 56 a 64 y de 65 años o más, donde el modelo discrimina peor (AUC de 0.714 y 0.707).
- **Acceso:** los afiliados no usan el sistema ni ven su puntaje; lo usa el personal, y el beneficio les llega por la llamada de confirmación.
- **Barreras:** podrían quedar excluidos quienes no tienen teléfono, tienen discapacidad auditiva o no hablan el idioma del equipo, y los pacientes sin historial, para quienes el modelo es menos preciso.

Parte 4. Riesgos éticos específicos

La Tabla 6 responde cada pregunta del checklist de la guía; la Tabla 7 desarrolla los seis riesgos prioritarios con la plantilla solicitada.

Tabla 6

Checklist de riesgos éticos aplicado al proyecto

Dimensión	Pregunta de la guía	Respuesta
Fairness y sesgo	¿Podría discriminar por género, raza, edad, etc.?	Sí: usa edad y sexo; con umbral único, menor cobertura en los grupos de 56 a 64 y de 65 años o más (31.7% y 30.6%)
	¿Los datos están balanceados?	No: 20.2% de inasistencias, 65% de mujeres y 13% de pacientes de 65 o más

Dimensión	Pregunta de la guía	Respuesta
	¿Se evaluaron métricas de fairness?	Sí: AUC y recall con IC por edad, sexo, programa social y barrio (Tabla 5)
Privacidad	¿Qué datos personales se recopilan?	Ninguno en el prototipo; en un uso real, edad, sexo, barrio, condiciones e historial de citas
	¿Hay consentimiento informado?	No aplica al dataset público y anónimo; en un uso real lo cubriría el aviso de privacidad del plan bajo HIPAA
	¿Los datos están protegidos?	Sí en el prototipo: la app no almacena datos; en un uso real, cifrado y control de acceso
	¿Existe riesgo de reidentificación?	Sí, en un uso real, por la combinación de edad, barrio e historial
Transparencia	¿Los usuarios entienden cómo funciona?	Sí: guía de uso en la app y manual de usuario
	¿Se comunican las limitaciones?	Sí: advertencia permanente y sección «Acerca del modelo»
	¿El modelo es explicable?	Sí: valores SHAP por predicción; riesgo de leerlos como causas
	¿Hay documentación accesible?	Sí: repositorio público con documentación técnica y ética
Autonomía	¿Los usuarios controlan las decisiones?	Sí: el coordinador decide y puede apartarse de la lista
	¿El sistema manipula o coacciona?	No: solo ordena llamadas; el afiliado no recibe presión del sistema
	¿Hay supervisión humana apropiada?	Sí, con riesgo de sesgo de automatización (R4)
Seguridad	¿Qué pasa si el modelo falla?	Se vuelve a la versión anterior o al orden de agenda
	¿Cuáles son las consecuencias de los errores?	Viajes perdidos (falsos negativos) o llamadas innecesarias (falsos positivos)
	¿Hay mecanismos de seguridad?	Sí: validación de entradas, pruebas y versionado de modelos
Accountability	¿Quién es responsable si algo sale mal?	La organización que lo despliega (Tabla 9)
	¿Hay proceso de apelación?	Parcial: canal de revisión para coordinadores; los afiliados apelan por medio del coordinador
	¿Existe auditoría del sistema?	Propuesta: trimestral de sesgo y externa anual

Tabla 7

Riesgos éticos prioritarios

Riesgo	Descripción en el proyecto	Evidencia	Severidad	Grupo afectado
R1. Discriminación por edad	La cobertura de las inasistencias cae con la edad si se usa un umbral único	Recall de 30.6% (65 o más) frente a 90.9% (19 a 35); AUC de 0.707 frente a 0.741	Alta	Adultos de 56 a 64 y de 65 años o más
R2. Privacidad y reidentificación	En un uso real, el historial de citas, la edad y el barrio son datos de salud	Pocas variables cuasiidentificadoras bastan para reidentificar a una persona	Alta	Todos los afiliados

Riesgo	Descripción en el proyecto	Evidencia	Severidad	Grupo afectado
	identificables			
R3. Explicaciones mal interpretadas	SHAP explica al modelo, no causas	El SMS aparece asociado a más inasistencias (27.6% frente a 16.7%), pero ajustado por antelación la razón de momios es 0.77	Media	Coordinadores y afiliados
R4. Sesgo de automatización	Seguir la lista sin criterio y dejar de confirmar visitas no marcadas	Fenómeno documentado (Parasuraman y Manzey, 2010); el 29% de las inasistencias no se marca	Media	Afiliados no marcados
R5. Apelación y auditoría incompletas	Los coordinadores pueden pedir revisión, pero el afiliado no tiene un canal formal propio y no hay auditoría periódica	La Sección 1557 exige mitigar la discriminación de las herramientas de apoyo (U.S. Department of Health and Human Services [HHS], 2024)	Media	Afiliados y organización
R6. Transferencia de dominio	Modelo entrenado con citas ambulatorias de Brasil (2016) y pensado para visitas domiciliarias de EE. UU.	Población, tipo de cita, época y canal de recordatorio distintos; ningún resultado se ha validado con datos de IHA/HRA	Alta	Todos los afiliados, en especial los adultos mayores

Priorización. R1, R2 y R6 son de severidad alta: R1 y R2 comprometen derechos (igualdad de trato por edad y privacidad de la salud) de grupos con poca voz, y R6 deja sin garantía todas las cifras del sistema en la población real. R3 a R5 son de severidad media porque dependen del uso y se corrigen con diseño y políticas.

Parte 5. Estrategias de mitigación

La Tabla 8 aplica la plantilla de la guía. Las estrategias aplicables en el prototipo ya están implementadas, total o parcialmente; la de R6 necesita datos del programa y queda planificada. Solo la efectividad de R1 está medida; en las demás se indica la esperada y su indicador.

Tabla 8

Estrategias de mitigación por riesgo

Riesgo a mitigar	Estrategia propuesta	Tipo	Implementación (pasos)	Cuándo / Responsable	Efectividad (medida o esperada) / Estado
R1. Discriminación por edad	Umbrales por grupo de edad con igual recall	Técnica y diseño	1) Recall por grupo con IC bootstrap. 2) Umbral por grupo con predicciones fuera de	Antes del despliegue y mensual / Data	Medida: recall de 65 o más de 30.6% a 74.0%

Riesgo a mitigar	Estrategia propuesta	Tipo	Implementación (pasos)	Cuándo / Responsable	Efectividad (medida o esperada) / Estado
	objetivo		muestra. 3) Activarlo por defecto en la app	scientist	y brecha de 0.603 a 0.037 / Implementada
R2. Privacidad	Minimización de datos y controles HIPAA	Política y diseño	1) Solo las 13 variables del modelo, sin nombres. 2) La app no almacena datos. 3) Cifrado, control de acceso y acuerdo de asociado comercial	Antes del despliegue / Oficial de privacidad	Esperada alta, no medida (incidentes y auditoría HIPAA) / Parcial (1 y 2)
R3. Explicaciones	Comunicar que SHAP no indica causas	Educación y diseño	1) Nota bajo cada explicación. 2) Ejemplo del SMS en la app. 3) Capacitación a coordinadores	Antes del despliegue / Equipo de desarrollo	Esperada media, no medida (encuesta de comprensión a coordinadores) / Parcial (1 y 2)
R4. Automatización	Supervisión humana obligatoria	Política y diseño	1) La app solo ordena; no cancela ni reprograma. 2) Confirmar también visitas no marcadas. 3) Revisar mensualmente las inasistencias no detectadas	Continuo / Líder de programación	Esperada media, no medida (inasistencias no marcadas que sí se confirmaron) / Parcial (1)
R5. Apelación y auditoría	Canal de revisión, vía formal para afiliados y auditoría	Política y diseño	1) Botón «Solicitar revisión» en cada predicción. 2) Integrar las objeciones de afiliados al proceso formal de quejas del plan. 3) Auditoría trimestral y externa anual	Antes del despliegue / Comité de ética	Esperada alta, no medida (solicitudes resueltas en plazo y hallazgos de auditoría) / Parcial (1)
R6. Transferencia de dominio	Reentrenar y revalidar con datos del programa	Técnica y política	1) Reentrenar con 12 meses o más de visitas IHA/HRA autorizadas. 2) Validar por paciente y en el tiempo; recalibrar umbrales. 3) Piloto en sombra de 8 a 12 semanas. 4) Desplegar solo con AUC de 0.70 o más, Brier menor que sin información y recall de 60% o más en cada grupo	Antes de cualquier uso real / Data scientist y product owner	Medible en el piloto (criterios del paso 4) / Planificada

Para el riesgo 1 de la Tabla 4 se suma una política: prohibir por escrito el uso del riesgo para negar, retrasar o sobreagendar visitas.

Justificación del uso de la edad en R1. A igual probabilidad, a una persona de 65 años o más se le ofrece la confirmación desde 0.182 y a una de 19 a 35, desde 0.306: es un trato distinto por edad. Se justifica porque el umbral único producía por sí mismo un efecto dispar (30.6% frente a 90.9% de cobertura), porque el ajuste solo busca igualar la probabilidad de recibir apoyo (Hardt et al., 2016) y solo ordena una llamada, sin quitar ni retrasar visitas, y porque la Sección 1557 no prohíbe usar la edad en estas herramientas, sino que exige identificar ese uso y mitigar su riesgo (HHS, 2024); la reglamentación de la Ley contra la Discriminación por Edad admite distinciones necesarias para el funcionamiento normal de un programa, beneficios especiales para adultos mayores y acciones afirmativas (Nondiscrimination on the basis of age, 2024, §§ 91.13, 91.16 y 91.17). Tiene costos: los jóvenes reciben menos confirmaciones (de 62.4% a 46.4% en 19 a 35, con recall de 72.9%) y los mayores, más llamadas innecesarias (precisión de 0.308 a 0.228). Por eso está documentado, puede desactivarse, se revisa cada trimestre y debe validarlo asesoría legal antes de un despliegue.

Cómo funciona hoy la apelación. Los coordinadores tienen el botón **Solicitar revisión** en cada predicción, con motivo y comentario sin datos identificables. El afiliado no ve su puntaje: si objeta, lo dice en la llamada y el coordinador registra la solicitud. Falta una vía formal propia del afiliado, integrada al proceso de quejas de Medicare Advantage y Medicaid (Grievance and appeal system, 2024; Grievance procedures, 2024).

Parte 6. Framework de responsabilidad

6.1 Cadena de responsabilidad

La Tabla 9 define qué responde cada rol y cómo rinde cuentas.

Tabla 9

Cadena de responsabilidad

Rol	Responsabilidades	Rendición de cuentas
Desarrolladores	Implementación técnica correcta y validación de entradas	Revisión de código, 18 pruebas unitarias y control de versiones
Data scientists	Calidad de datos, ausencia de fuga y equidad	Auditoría de sesgo por edad, sexo y proxies socioeconómicos en cada versión
Product owner (líder de programación)	Diseño, umbrales, capacidad y revisión de solicitudes	Documentación de trade-offs (precisión de 0.334 a 0.320)
Coordinadores (usuarios)	Decisión final sobre cada visita	Registro de solicitudes de revisión
Organización	Gobernanza, recursos, privacidad y cumplimiento	Políticas de uso, comité de ética y coordinador de la Sección 1557

6.2 Mecanismos de accountability

La Tabla 10 resume el estado de cada mecanismo del checklist de la guía.

Tabla 10

Mecanismos de accountability

Categoría	Mecanismo	Estado	Evidencia o frecuencia
Documentación	Model card	Cumplido	models/README.md y docs/arquitectura.md (Mitchell et al., 2019)
	Datasheet de los datos	Cumplido	data/README.md (Gebru et al., 2021)
	Ethics statement	Cumplido	docs/consideraciones_eticas.md y este análisis
Supervisión	Revisión humana en decisiones críticas	Cumplido	El sistema solo ordena; el coordinador decide
	Proceso de apelación para usuarios	Parcial	Coordinadores: «Solicitar revisión»; afiliados: vía el coordinador
	Auditoría periódica	Propuesto	Frecuencia: trimestral (sesgo) y anual (externa)
Monitoreo continuo	Métricas de fairness	Propuesto	Recall y AUC por edad, sexo, programa social y barrio, mensual
	Alertas por drift o anomalías	Propuesto	Recall de un grupo bajo 60% o Brier 10% mayor
	Reporte de incidentes	Parcial	Solicitudes de revisión e Issues del repositorio
Transparencia	Información sobre el uso de IA	Cumplido	Título, aviso y guía de uso en la app
	Comunicación de limitaciones	Cumplido	Advertencia y sección «Acerca del modelo»
	Acceso a explicaciones	Cumplido	Gráfico SHAP en cada predicción

6.3 Plan de respuesta a incidentes

- **Detección:** alertas del monitoreo mensual y solicitudes de revisión.
- **Respuesta inmediata:** volver a la versión validada anterior o confirmar por orden de agenda.
- **Investigación:** métricas por subgrupo, datos de entrada y SHAP de los casos afectados.
- **Corrección:** reprogramar con prioridad las visitas perjudicadas y reentrenar o recalibrar.
- **Prevención:** nueva prueba o alerta y actualización de la documentación y la capacitación.

Parte 7. Consideraciones de compliance

Tabla 11

Regulaciones aplicables

Regulación	¿Qué requiere?	¿El proyecto cumple?	Cambios necesarios
HIPAA	Proteger la información de salud	Sí en el prototipo (sin PHI)	Acuerdo de asociado, cifrado y control de acceso
Antidiscriminación: Sección 1557 (45 CFR § 92.210) y Ley de Discriminación por Edad	Mitigar la discriminación de herramientas que usan edad o sexo	Parcial: uso de la edad justificado y mitigado (Parte 5)	Inventario, auditoría y validación legal (HHS, 2024)
CCPA/CPRA	Derechos sobre datos personales (PHI en gran parte exenta)	No aplica al prototipo	Revisar datos no cubiertos por HIPAA
GDPR	Base legal para datos de salud	No aplica (población de EE. UU.)	Ninguno
AI Act de la UE	Alto riesgo si evalúa el acceso a salud	No aplica; solo ordena	Alto riesgo si decidiera el acceso
Leyes laborales	Uso justo de métricas del personal	Sí: no evalúa a los NP	Prohibirlo por escrito
Otros: LGPD (Brasil) y quejas de Medicare y Medicaid	LGPD no aplica a datos anonimizados; los planes deben tener un proceso de quejas	Sí (LGPD); parcial (quejas)	Integrar objeciones de afiliados a las quejas

La Tabla 11 recorre el checklist de la guía; el AI Act corresponde al Reglamento (UE) 2024/1689 (2024) y la LGPD a la Lei n.º 13.709 (2018). Un despliegue real requeriría asesoría legal.

Parte 8. Reflexión y compromiso

8.1 Reflexión grupal

1. Dilema: priorizar donde el modelo acierta más ahorra millas, pero deja a los mayores con menos confirmaciones. *Valores en conflicto:* eficiencia y justicia (Beauchamp y Childress, 2019). *Resolución:* el riesgo solo puede **agregar** apoyo, aunque cueste precisión (de 0.334 a 0.320).

2. Aprendimos que una métrica global oculta brechas por subgrupo (Obermeyer et al., 2019), que un beneficio simulado debe mostrarse con la sensibilidad de sus supuestos y que no consultamos a NP ni afiliados. 3. Cambios: ya agregamos el canal de revisión y la evaluación por sexo y proxies; faltan la vía formal para afiliados, esa consulta y la revalidación con datos del programa.

8.2 Compromiso ético

Como creadores de este sistema de IA, nos comprometemos a:

- Evaluar mensualmente el recall y el AUC por grupo de edad, sexo, programa social y barrio.
- No permitir que el riesgo se use para negar, retrasar o sobreagendar visitas.
- Reentrenar y revalidar el modelo con datos autorizados antes de cualquier uso real.
- Actuar responsablemente si se identifican daños.
- Priorizar el bienestar de los usuarios y de los grupos vulnerables.
- Mantener la transparencia sobre las limitaciones del sistema.

Firma/Fecha: Romel Alberto Vera Macías y Jhon Henry Quimi Loza, 5 de octubre de 2026; versión revisada el 21 de octubre de 2026.

Referencias

Beauchamp, T. L., y Childress, J. F. (2019). *Principles of biomedical ethics* (8.ª ed.). Oxford University Press.

Centers for Medicare & Medicaid Services. (s. f.). *NPI Registry* [Base de datos]. Recuperado el 18 de septiembre de 2026, de https://npiregistry.cms.hhs.gov/

Dantas, L. F., Fleck, J. L., Cyrino Oliveira, F. L., y Hamacher, S. (2018). No-shows in appointment scheduling: A systematic literature review. *Health Policy, 122*(4), 412–421. https://doi.org/10.1016/j.healthpol.2018.02.002

Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., y Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM, 64*(12), 86–92. https://doi.org/10.1145/3458723

Grievance and appeal system, 42 C.F.R. pt. 438, subpt. F (2024). https://www.ecfr.gov/current/title-42/chapter-IV/subchapter-C/part-438/subpart-F

Grievance procedures, 42 C.F.R. § 422.564 (2024). https://www.ecfr.gov/current/title-42/chapter-IV/subchapter-B/part-422/subpart-M/section-422.564

Hardt, M., Price, E., y Srebro, N. (2016). Equality of opportunity in supervised learning. En *Advances in Neural Information Processing Systems* (Vol. 29, pp. 3315–3323). Curran Associates.

Hoppen, J. (2016). *Medical appointment no shows* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/joniarroba/noshowappointments

Lei n.º 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). (2018). *Diário Oficial da União*. https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., y Gebru, T. (2019). Model cards for model reporting. En *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220–229). ACM. https://doi.org/10.1145/3287560.3287596

Nondiscrimination on the basis of age in programs or activities receiving Federal financial assistance from HHS, 45 C.F.R. pt. 91 (2024). https://www.ecfr.gov/current/title-45/subtitle-A/subchapter-A/part-91

Obermeyer, Z., Powers, B., Vogeli, C., y Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. *Science, 366*(6464), 447–453. https://doi.org/10.1126/science.aax2342

Parasuraman, R., y Manzey, D. H. (2010). Complacency and bias in human use of automation: An attentional integration. *Human Factors, 52*(3), 381–410. https://doi.org/10.1177/0018720810376055

Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, por el que se establecen normas armonizadas en materia de inteligencia artificial. (2024). *Diario Oficial de la Unión Europea*, L 2024/1689. https://eur-lex.europa.eu/eli/reg/2024/1689/oj

Robotham, D., Satkunanathan, S., Reynolds, J., Stahl, D., y Wykes, T. (2016). Using digital notifications to improve attendance in clinic: Systematic review and meta-analysis. *BMJ Open, 6*(10), e012116. https://doi.org/10.1136/bmjopen-2016-012116

U.S. Census Bureau. (2023). *2023 Gazetteer files: ZIP Code Tabulation Areas* [Conjunto de datos]. https://www2.census.gov/geo/docs/maps-data/data/gazetteer/2023_Gazetteer/2023_Gaz_zcta_national.zip

U.S. Department of Health and Human Services. (2024). Nondiscrimination in health programs and activities. *Federal Register, 89*(88), 37522–37703. https://www.federalregister.gov/d/2024-08711