Workshop: Impacto Social y Responsabilidad en el Proyecto de IA

Sistema Inteligente de Priorización de Riesgo y Asignación de Visitas Domiciliarias de Salud

Romel Alberto Vera Macías

Jhon Henry Quimi Loza

Maestría en Inteligencia Artificial, Universidad Espíritu Santo (UEES)

Proyecto Integrador

Docente: Gladys María Villegas Rugel

Octubre de 2026

Parte 1. Contexto del proyecto

1.1 Descripción del sistema

Problema. En los programas de valoración de salud en el hogar (IHA/HRA) que administran aseguradoras de Estados Unidos para afiliados de Medicare, Medicaid y Marketplace, cerca del 23% de las citas termina en inasistencia (Dantas et al., 2018), y el personal clínico itinerante (Nurse Practitioners, NP) se asigna solo por cercanía, por lo que cada inasistencia es un viaje desperdiciado.

Funcionalidad. Un modelo de Gradient Boosting estima la probabilidad de inasistencia de cada visita (AUC de 0.741), la explica con SHAP y la combina con la distancia para ordenar qué visitas confirmar primero, con umbrales por grupo de edad y un canal para solicitar la revisión humana de cada predicción, en una interfaz web en Streamlit.

Usuarios y dominio. Lo usan los coordinadores de programación; benefician de forma indirecta a afiliados y NP. El dominio es la salud preventiva en el hogar, regulado y con población vulnerable.

1.2 Alcance de implementación

Se implementaría en el equipo de programación de un programa IHA/HRA como herramienta interna; hoy es un prototipo con datos públicos (Hoppen, 2016). Afectaría a todos los afiliados con visita agendada (miles por mes en programas multiestatales, muchos de ellos adultos mayores), a los coordinadores y a los NP.

Decisiones que informa. El sistema no toma decisiones: informa el orden de las llamadas de confirmación y sugiere qué fracción de visitas confirmar primero según la capacidad del equipo. No decide quién recibe una visita, no cancela ni reprograma citas y no cambia la

asignación geográfica de los NP; la decisión final siempre es del coordinador, que puede apartarse de la recomendación.

Parte 2. Análisis de stakeholders

Se identificaron cinco grupos de stakeholders (Tabla 1). La Tabla 2 responde, para cada uno, las tres preguntas de la guía.

Tabla 1

Stakeholders del sistema: beneficios, riesgos y poder

Stakeholder	Descripción	Beneficios	Riesgos	Poder/ Voz
Afiliados	Personas con una visita agendada	Visita confirmada a tiempo; menos reprogramaciones	Trato distinto por su riesgo; percepción de vigilancia; errores del modelo	Bajo
Adultos mayores y afiliados de bajos ingresos	Subgrupos vulnerables (65 años o más; Medicaid)	Con la mitigación, cobertura similar a la del resto	Sin mitigación, solo 30.6% de sus inasistencias detectadas; el barrio actúa como indicador socioeconómico	Bajo
Coordinadores de programación	Usuarios directos	Lista priorizada y explicada	Sesgo de automatización; más llamadas (45.1% de citas señaladas)	Medio
Nurse Practitioners	Personal que viaja a los domicilios	12.6% menos millas desperdiciadas (simulación)	Cambios de ruta; uso de métricas para evaluarlos	Medio
Organización (aseguradora)	Responsable del programa y de los datos	Más visitas con la misma dotación	Riesgo legal y reputacional (discriminación, privacidad)	Alto

Tabla 2

Efecto en cada stakeholder, consideración en el diseño y protección de sus intereses

Stakeholder	¿Cómo lo afecta?	¿Considerado en el diseño?	¿Cómo se protegen sus intereses?
Afiliados	Cambia el orden de su llamada de confirmación, no su derecho a la visita	Sí: desempeño evaluado por subgrupos	Uso limitado a confirmar; pueden objetar en la llamada y el coordinador pide revisión
Adultos mayores y bajos ingresos	Sin corrección, recibirían menos confirmaciones	Sí: motivó una mitigación implementada	Umbrales por grupo de edad: recall de 70.3% a 74.0% en todos
Coordinadores	Confirman primero las visitas marcadas	Sí: interfaz para usuarios no técnicos	Deciden, ven la explicación SHAP y pueden pedir revisión
Nurse Practitioners	Menos visitas sin paciente	Parcialmente: no fueron consultados	Asignación por cercanía intacta; no se usa para evaluarlos

Stakeholder	¿Cómo lo afecta?	¿Considerado en el diseño?	¿Cómo se protegen sus intereses?
Organización	Más eficiencia, con responsabilidad legal	Sí: limitaciones y regulación documentadas	Documentación, versionado, pruebas y monitoreo

Parte 3. Evaluación de impacto social

3.1 Impactos positivos

1. Menos desplazamiento desperdiciado del personal clínico. *Descripción:* confirmar primero el 20% de visitas con mayor riesgo por distancia evita viajes a domicilios donde nadie atenderá. *Grupos beneficiados:* NP y organización. *Evidencia:* en la simulación de Monte Carlo (2,000 réplicas), el desplazamiento desperdiciado bajó 12.6% (IC 95%: 9.5 a 15.7), frente a 8.9% con solo la distancia y 5.0% al azar, suponiendo que la confirmación reduce las inasistencias en 25% (Robotham et al., 2016).

2. Más valoraciones preventivas efectivas. *Descripción:* cada inasistencia evitada o reprogramada a tiempo es una valoración que sí ocurre. *Grupos beneficiados:* afiliados con condiciones crónicas. *Evidencia:* el modelo detecta el 71.0% de las inasistencias, frente al 1.7% con el umbral por defecto de 0.5.

3. Cobertura más equitativa entre grupos de edad. *Descripción:* la probabilidad de que una inasistencia real sea detectada y reciba confirmación pasa a ser similar entre grupos de edad, aunque no idéntica. *Grupos beneficiados:* adultos de 56 años o más. *Evidencia:* el recall del grupo de 65 años o más subió de 30.6% a 74.0%, la diferencia de igualdad de oportunidades bajó de 0.603 a 0.037 (Hardt et al., 2016) y todos los grupos quedaron entre 70.3% y 74.0%; el porcentaje de citas señaladas sigue variando por grupo (de 41.7% a 49.9%), porque sus tasas de inasistencia son distintas.

3.2 Impactos negativos y riesgos

La Tabla 3 presenta los cuatro impactos negativos o riesgos, con su severidad y su probabilidad.

Tabla 3

Impactos negativos y riesgos sociales

Riesgo o impacto negativo	Descripción del riesgo	Grupos vulnerables	Severidad	Probabilidad
1. Uso del riesgo para restringir atención	Emplear la probabilidad para no visitar, retrasar o sobreagendar a quienes más faltan	Afiliados con barreras de acceso (transporte, movilidad, bajos ingresos)	Alta	Media
2. Errores del modelo	Con un AUC de 0.741, el 29% de las inasistencias no se detecta y dos de cada tres citas señaladas son falsas alarmas	Todos; los falsos negativos pesan más en los adultos mayores	Media	Alta
3. Indicadores socioeconómicos	El barrio y el programa social elevan el riesgo estimado y concentran más llamadas en comunidades pobres	Afiliados de bajos ingresos y de barrios con alta inasistencia	Media	Media
4. Transferencia de dominio	Entrenado con citas ambulatorias de Brasil (2016), no con visitas domiciliarias de EE. UU.	Todos los afiliados, si se usa sin reentrenar	Alta	Alta

3.3 Análisis de equidad

¿Reduce o aumenta las desigualdades? Sin mitigación ni supervisión las **aumentaría**; con umbrales por grupo de edad y uso limitado a confirmar visitas, las **reduce**, porque dirige más apoyo a quien tiene más probabilidad de perder su visita.

- **Distribución de beneficios:** los beneficios operativos se concentran en la organización y los NP; los afiliados se benefician de forma indirecta, con más visitas que sí ocurren.
- **Distribución de riesgos:** los asumen los afiliados con alto riesgo estimado (más contactos) y los adultos mayores, donde el modelo discrimina peor (AUC de 0.707).
- **Acceso:** los afiliados no usan el sistema ni ven su puntaje; lo usa el personal, y el beneficio les llega por la llamada de confirmación.

- **Barreras:** podrían quedar excluidos quienes no tienen teléfono, tienen discapacidad auditiva o no hablan el idioma del equipo, y los pacientes sin historial, para quienes el modelo es menos preciso.

Parte 4. Riesgos éticos específicos

La Tabla 4 responde cada pregunta del checklist de la guía; la Tabla 5 desarrolla los cinco riesgos prioritarios con la plantilla solicitada.

Tabla 4

Checklist de riesgos éticos aplicado al proyecto

Dimensión	Pregunta de la guía	Respuesta
Fairness y sesgo	¿Podría discriminar por género, raza, edad, etc.?	Sí: usa edad y sexo; con umbral único, menor cobertura en mayores de 56 años
	¿Los datos están balanceados?	No: 20.2% de inasistencias, 65% de mujeres y 13% de pacientes de 65 o más
	¿Se evaluaron métricas de fairness?	Sí: AUC y recall por grupo con IC bootstrap e igualdad de oportunidades
Privacidad	¿Qué datos personales se recopilan?	Ninguno en el prototipo; en un uso real, edad, sexo, barrio, condiciones e historial de citas
	¿Hay consentimiento informado?	No aplica al dataset público y anónimo; en un uso real lo cubriría el aviso de privacidad del plan bajo HIPAA
	¿Los datos están protegidos?	Sí en el prototipo: la app no almacena datos; en un uso real, cifrado y control de acceso
	¿Existe riesgo de reidentificación?	Sí, en un uso real, por la combinación de edad, barrio e historial
Transparencia	¿Los usuarios entienden cómo funciona?	Sí: guía de uso en la app y manual de usuario
	¿Se comunican las limitaciones?	Sí: advertencia permanente y sección «Acerca del modelo»
	¿El modelo es explicable?	Sí: valores SHAP por predicción; riesgo de leerlos como causas
	¿Hay documentación accesible?	Sí: repositorio público con documentación técnica y ética
Autonomía	¿Los usuarios controlan las decisiones?	Sí: el coordinador decide y puede apartarse de la lista
	¿El sistema manipula o coacciona?	No: solo ordena llamadas; el afiliado no recibe presión del sistema
	¿Hay supervisión humana apropiada?	Sí, con riesgo de sesgo de automatización (R4)
Seguridad	¿Qué pasa si el modelo falla?	Se vuelve a la versión anterior o al orden de agenda

Dimensión	Pregunta de la guía	Respuesta
	¿Cuáles son las consecuencias de los errores?	Viajes perdidos (falsos negativos) o llamadas innecesarias (falsos positivos)
	¿Hay mecanismos de seguridad?	Sí: validación de entradas, pruebas y versionado de modelos
Accountability	¿Quién es responsable si algo sale mal?	La organización que lo despliega (Tabla 7)
	¿Hay proceso de apelación?	Parcial: canal de revisión para coordinadores; los afiliados apelan por medio del coordinador
	¿Existe auditoría del sistema?	Propuesta: trimestral de sesgo y externa anual

Tabla 5

Riesgos éticos prioritarios

Riesgo	Descripción en el proyecto	Evidencia	Severidad	Grupo afectado
R1. Discriminación por edad	La cobertura de las inasistencias cae con la edad si se usa un umbral único	Recall de 30.6% (65 o más) frente a 90.9% (19 a 35); AUC de 0.707 frente a 0.741	Alta	Adultos de 56 años o más
R2. Privacidad y reidentificación	En un uso real, el historial de citas, la edad y el barrio son datos de salud identificables	Pocas variables cuasiidentificadoras bastan para reidentificar a una persona	Alta	Todos los afiliados
R3. Explicaciones mal interpretadas	SHAP explica al modelo, no causas	El SMS aparece asociado a más inasistencias (27.6% frente a 16.7%), pero ajustado por antelación la razón de momios es 0.77	Media	Coordinadores y afiliados
R4. Sesgo de automatización	Seguir la lista sin criterio y dejar de confirmar visitas no marcadas	Fenómeno documentado (Parasuraman y Manzey, 2010); el 29% de las inasistencias no se marca	Media	Afiliados no marcados
R5. Apelación y auditoría incompletas	Los coordinadores pueden pedir revisión, pero el afiliado no tiene un canal formal propio y no hay auditoría periódica	La Sección 1557 exige mitigar la discriminación de las herramientas de apoyo (U.S. Department of Health and Human Services [HHS], 2024)	Media	Afiliados y organización

Priorización. R1 y R2 son de severidad alta porque comprometen derechos (igualdad de trato por edad y privacidad de la información de salud) y su daño recae en grupos con poca voz; R3 a R5 son de severidad media porque dependen del uso del sistema y se corrigen con diseño y políticas.

Parte 5. Estrategias de mitigación

La Tabla 6 aplica la plantilla de la guía a cada riesgo. Como pide la guía para el proyecto final, las estrategias de alta prioridad ya están implementadas, total o parcialmente.

Tabla 6

Estrategias de mitigación por riesgo

Riesgo a mitigar	Estrategia propuesta	Tipo	Implementación (pasos)	Cuándo / Responsable	Efectividad / Estado
R1. Discriminación por edad	Umbrales por grupo de edad con igual recall objetivo	Técnica y diseño	1) Recall por grupo con IC bootstrap. 2) Umbral por grupo con predicciones fuera de muestra. 3) Activarlo por defecto en la app	Antes del despliegue y mensual / Data scientist	Alta / **Implementada**
R2. Privacidad	Minimización de datos y controles HIPAA	Política y diseño	1) Solo las 13 variables del modelo, sin nombres. 2) La app no almacena datos. 3) Cifrado, control de acceso y acuerdo de asociado comercial	Antes del despliegue / Oficial de privacidad	Alta / Parcial (1 y 2)
R3. Explicaciones	Comunicar que SHAP no indica causas	Educación y diseño	1) Nota bajo cada explicación. 2) Ejemplo del SMS en la app. 3) Capacitación a coordinadores	Antes del despliegue / Equipo de desarrollo	Media / Parcial (1 y 2)
R4. Automatización	Supervisión humana obligatoria	Política y diseño	1) La app solo ordena; no cancela ni reprograma. 2) Confirmar también visitas no marcadas. 3) Revisar mensualmente las inasistencias no detectadas	Continuo / Líder de programación	Media / Parcial (1)
R5. Apelación y auditoría	Canal de revisión, vía formal para afiliados y auditoría	Política y diseño	1) Botón «Solicitar revisión» en cada predicción. 2) Integrar las objeciones de afiliados al proceso formal de quejas del plan. 3) Auditoría trimestral y externa anual	Antes del despliegue / Comité de ética	Alta / Parcial (1)

Para los riesgos 1 y 4 de la Tabla 3 se suman dos políticas: prohibir por escrito el uso del riesgo para negar o retrasar visitas, y exigir reentrenar con datos del programa real antes de cualquier uso.

Cómo funciona hoy la apelación. Los usuarios del sistema son los coordinadores, y para ellos el canal está implementado: cada predicción tiene un botón **Solicitar revisión**, con un motivo y un comentario sin datos identificables, que queda pendiente de revisión humana. El

afiliado no ve su puntaje; si objeta una llamada o una reprogramación, lo dice durante la confirmación y el coordinador registra la solicitud con el motivo correspondiente. Lo que falta es una vía formal propia del afiliado, que se propone integrar al proceso de quejas que los planes de Medicare Advantage y Medicaid ya deben tener (Grievance and appeal system, 2024; Grievance procedures, 2024).

Parte 6. Framework de responsabilidad

6.1 Cadena de responsabilidad

La Tabla 7 define qué responde cada rol y cómo rinde cuentas.

Tabla 7

Cadena de responsabilidad

Rol	Responsabilidades	Rendición de cuentas
Desarrolladores	Implementación técnica correcta y validación de entradas	Revisión de código, 18 pruebas unitarias y control de versiones
Data scientists	Calidad de datos, ausencia de fuga y equidad	Auditoría de sesgo por edad y sexo en cada versión
Product owner (líder de programación)	Diseño, umbrales, capacidad y revisión de solicitudes	Documentación de trade-offs (precisión de 0.334 a 0.320)
Coordinadores (usuarios)	Decisión final sobre cada visita	Registro de solicitudes de revisión
Organización	Gobernanza, recursos, privacidad y cumplimiento	Políticas de uso, comité de ética y coordinador de la Sección 1557

6.2 Mecanismos de accountability

La Tabla 8 resume el estado de cada mecanismo del checklist de la guía.

Tabla 8

Mecanismos de accountability

Categoría	Mecanismo	Estado	Evidencia o frecuencia
Documentación	Model card	Cumplido	models/README.md y docs/arquitectura.md (Mitchell et al., 2019)
	Datasheet de los datos	Cumplido	data/README.md (Gebru et al., 2021)
	Ethics statement	Cumplido	docs/consideraciones_eticas.md y este análisis
Supervisión	Revisión humana en decisiones críticas	Cumplido	El sistema solo ordena; el coordinador decide

Categoría	Mecanismo	Estado	Evidencia o frecuencia
	Proceso de apelación para usuarios	Parcial	Coordinadores: «Solicitar revisión»; afiliados: vía el coordinador
	Auditoría periódica	Propuesto	Frecuencia: trimestral (sesgo) y anual (externa)
Monitoreo continuo	Métricas de fairness	Propuesto	Recall y AUC por grupo, mensual
	Alertas por drift o anomalías	Propuesto	Recall de un grupo bajo 60% o Brier 10% mayor
	Reporte de incidentes	Parcial	Solicitudes de revisión e Issues del repositorio
Transparencia	Información sobre el uso de IA	Cumplido	Título, aviso y guía de uso en la app
	Comunicación de limitaciones	Cumplido	Advertencia y sección «Acerca del modelo»
	Acceso a explicaciones	Cumplido	Gráfico SHAP en cada predicción

6.3 Plan de respuesta a incidentes

- **Detección:** alertas del monitoreo mensual y solicitudes de revisión.
- **Respuesta inmediata:** volver a la versión validada anterior o confirmar por orden de agenda.
- **Investigación:** métricas por subgrupo, datos de entrada y SHAP de los casos afectados.
- **Corrección:** reprogramar con prioridad las visitas perjudicadas y reentrenar o recalibrar.
- **Prevención:** nueva prueba o alerta y actualización de la documentación y la capacitación.

Parte 7. Consideraciones de compliance

Tabla 9

Regulaciones aplicables

Regulación	¿Qué requiere?	¿El proyecto cumple?	Cambios necesarios
HIPAA	Proteger la información de salud	Sí en el prototipo (sin PHI)	Acuerdo de asociado, cifrado y control de acceso
Antidiscriminación: Sección 1557 (45 CFR § 92.210) y Ley de Discriminación por Edad	Mitigar la discriminación de herramientas que usan edad o sexo	Parcial: equidad por edad mitigada	Inventario y auditoría (HHS, 2024)
CCPA/CPRA	Derechos sobre datos personales (PHI en gran parte exenta)	No aplica al prototipo	Revisar datos no cubiertos por HIPAA
GDPR	Base legal para datos de salud	No aplica (población de EE. UU.)	Ninguno
AI Act de la UE	Alto riesgo si evalúa el acceso a salud	No aplica; solo ordena	Alto riesgo si decidiera el acceso

Regulación	¿Qué requiere?	¿El proyecto cumple?	Cambios necesarios
Leyes laborales	Uso justo de métricas del personal	Sí: no evalúa a los NP	Prohibirlo por escrito
Otros: LGPD (Brasil) y quejas de Medicare y Medicaid	LGPD no aplica a datos anonimizados; los planes deben tener un proceso de quejas	Sí (LGPD); parcial (quejas)	Integrar objeciones de afiliados a las quejas

La Tabla 9 recorre el checklist de la guía; el AI Act corresponde al Reglamento (UE) 2024/1689 (2024) y la LGPD a la Lei n.º 13.709 (2018). Un despliegue real requeriría asesoría legal.

Parte 8. Reflexión y compromiso

8.1 Reflexión grupal

1. Dilema: priorizar donde el modelo acierta más ahorra millas, pero deja a los mayores con menos confirmaciones. *Valores en conflicto:* eficiencia y justicia (Beauchamp y Childress, 2019). *Resolución:* el riesgo solo puede **agregar** apoyo, aunque cueste precisión (de 0.334 a 0.320).

2. Aprendimos que una métrica global oculta brechas por subgrupo (Obermeyer et al., 2019) y que no consultamos a NP ni afiliados. **3. Cambios:** ya agregamos el canal de revisión; faltan la vía formal para afiliados y esa consulta.

8.2 Compromiso ético

Como creadores de este sistema de IA, nos comprometemos a:

- Evaluar mensualmente el recall y el AUC por grupo de edad y sexo.
- No permitir que el riesgo se use para negar, retrasar o sobreagendar visitas.
- Reentrenar y revalidar el modelo con datos autorizados antes de cualquier uso real.
- Actuar responsablemente si se identifican daños.
- Priorizar el bienestar de los usuarios y de los grupos vulnerables.
- Mantener la transparencia sobre las limitaciones del sistema.

Firma/Fecha: Romel Alberto Vera Macías y Jhon Henry Quimi Loza, 5 de octubre de 2026.

Referencias

Beauchamp, T. L., y Childress, J. F. (2019). *Principles of biomedical ethics* (8.ª ed.). Oxford University Press.

Dantas, L. F., Fleck, J. L., Cyrino Oliveira, F. L., y Hamacher, S. (2018). No-shows in appointment scheduling: A systematic literature review. *Health Policy, 122*(4), 412–421. https://doi.org/10.1016/j.healthpol.2018.02.002

Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., y Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM, 64*(12), 86–92. https://doi.org/10.1145/3458723

Grievance and appeal system, 42 C.F.R. pt. 438, subpt. F (2024). https://www.ecfr.gov/current/title-42/chapter-IV/subchapter-C/part-438/subpart-F

Grievance procedures, 42 C.F.R. § 422.564 (2024). https://www.ecfr.gov/current/title-42/chapter-IV/subchapter-B/part-422/subpart-M/section-422.564

Hardt, M., Price, E., y Srebro, N. (2016). Equality of opportunity in supervised learning. En *Advances in Neural Information Processing Systems* (Vol. 29, pp. 3315–3323). Curran Associates.

Hoppen, J. (2016). *Medical appointment no shows* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/joniarroba/noshowappointments

Lei n.º 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). (2018). *Diário Oficial da União*. https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., y Gebru, T. (2019). Model cards for model reporting. En *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220–229). ACM. https://doi.org/10.1145/3287560.3287596

Obermeyer, Z., Powers, B., Vogeli, C., y Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. *Science, 366*(6464), 447–453. https://doi.org/10.1126/science.aax2342

Parasuraman, R., y Manzey, D. H. (2010). Complacency and bias in human use of automation: An attentional integration. *Human Factors, 52*(3), 381–410. https://doi.org/10.1177/0018720810376055

Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, por el que se establecen normas armonizadas en materia de inteligencia artificial. (2024). *Diario Oficial de la Unión Europea*, L 2024/1689. https://eur-lex.europa.eu/eli/reg/2024/1689/oj

Robotham, D., Satkunanathan, S., Reynolds, J., Stahl, D., y Wykes, T. (2016). Using digital notifications to improve attendance in clinic: Systematic review and meta-analysis. *BMJ Open, 6*(10), e012116. https://doi.org/10.1136/bmjopen-2016-012116

U.S. Department of Health and Human Services. (2024). Nondiscrimination in health programs and activities. *Federal Register, 89*(88), 37522–37703. https://www.federalregister.gov/d/2024-08711